

机器学习

Machine learning

第九章 概率图模型

Probabilistic Graphical Model

授课人：周晓飞

zhouxiaofei@iie.ac.cn

2020-12-05

# 第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断

9.5 实例模型

# 第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断



9.5 实例模型

# 有向图模型：贝叶斯网络

## 图结构：有向无环图（DAG）

**结点**：一个或一组随机变量。

**边**：随机变量之间的单向、直接影响（加班 → 生病）。




# 有向图模型：贝叶斯网络

## 图结构：有向无环图（DAG）

**结点**：一个或一组随机变量。

**边**：随机变量之间的单向、直接影响（加班  $\rightarrow$  生病）。



- 当前结点： $x_3$
- 父结点： $\{x_1\}$
- 子结点： $\{x_5\}$
- 祖先结点： $\{x_1\}$
- 后代结点： $\{x_5, x_6\}$
- 马尔可夫毯： $\{x_1, x_2, x_5\}$

祖先：所有长辈节点

后代：所有后继节点

贝叶斯网 **MB**：子结点、父结点、子结点的父节点


# 有向图模型：贝叶斯网络

## 联合概率分布

分解形式：

$$P(\mathbf{x}) = \prod_{i=1}^n P(x_i | \mathbf{x}_{\pi_i})$$

其中， $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ ； $\mathbf{x}_{\pi_i}$  为  $x_i$  所有父结点构成的集合。




$$\begin{aligned} &P(x_1, x_2, x_3, x_4, x_5, x_6) \\ &= P(x_1)P(x_2|x_1)P(x_3|x_1)P(x_4|x_2) \\ &\quad P(x_5|x_2, x_3)P(x_6|x_2, x_5) \end{aligned}$$

# 有向图模型： 贝叶斯网络

## 示例：朴素贝叶斯


$\mathbf{x} = (x_1, x_2, \dots, x_n)$  为特征向量， $y$  是类别标签。



$$P(\mathbf{x}, y) = P(y) \prod_{i=1}^n P(x_i | y)$$

# 有向图模型：贝叶斯网络

## 示例：草坪问题




- 同时观测到下雨、给草坪浇水、草坪湿的概率有多大？
- 当已知不下雨时，观测到草坪湿的概率有多大？
- 当观测到草坪湿以后，推测下雨的概率有多大？
- 当观测到草坪湿以后，推测给草坪浇过水的概率有多大？

... ..



# 有向图模型： 贝叶斯网络

## 示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

$R$	$P(S = 1)$	$P(S = 0)$	$P(R = 1)$	$P(R = 0)$
1	0.01	0.99	0.2	0.8
0	0.4	0.6		

$S$	$R$	$P(G = 1)$	$P(G = 0)$
1	1	0.99	0.01
1	0	0.9	0.1
0	1	0.8	0.2
0	0	0.0	1.0

# 有向图模型： 贝叶斯网络

## 示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

同时观测到下雨、给草坪浇水、草坪湿的概率有多大？

$$\begin{aligned} P(G = 1, S = 1, R = 1) \\ &= P(G = 1 | S = 1, R = 1)P(S = 1 | R = 1)P(R = 1) \\ &= 0.99 \times 0.01 \times 0.2 = 0.00198 \end{aligned}$$

# 有向图模型：贝叶斯网络

## 示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

当已知不下雨时，观测到草坪湿的概率有多大？

$$\begin{aligned} P(G = 1 | R = 0) &= \frac{P(G = 1, R = 0)}{P(R = 0)} = \frac{\sum_{S \in \{1, 0\}} P(G = 1, S, R = 0)}{P(R = 0)} \\ &= \frac{0.288 + 0}{0.8} = 0.36 \end{aligned}$$

# 有向图模型：贝叶斯网络

## 示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

当观测到草坪湿以后，推测下雨的概率有多大？

$$\begin{aligned} P(R = 1 | G = 1) &= \frac{P(G = 1, R = 1)}{P(G = 1)} = \frac{\sum_{S \in \{1, 0\}} P(G = 1, S, R = 1)}{\sum_{S, R \in \{1, 0\}} P(G = 1, S, R)} \\ &= \frac{0.00198 + 0.1584}{0.00198 + 0.288 + 0.1584 + 0.0} \approx 0.3577 \end{aligned}$$

# 有向图模型：贝叶斯网络

## 示例：草坪问题



$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$




当观测到草坪湿以后，推测给草坪浇过水的概率有多大？

$$\begin{aligned} P(S = 1 | G = 1) &= \frac{P(G = 1, S = 1)}{P(G = 1)} = \frac{\sum_{R \in \{1, 0\}} P(G = 1, S = 1, R)}{\sum_{S, R \in \{1, 0\}} P(G = 1, S, R)} \\ &= \frac{0.00198 + 0.288}{0.00198 + 0.288 + 0.1584 + 0.0} \approx 0.6467 \end{aligned}$$

# 有向图模型：贝叶斯网络

## 条件独立性


**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。



# 有向图模型：贝叶斯网络

## 条件独立性

**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。




$$\begin{aligned} P(A, B|C) &= \frac{P(A, B, C)}{P(C)} \\ &= \frac{P(C)P(A|C)P(B|C)}{P(C)} \\ &= P(A|C)P(B|C) \end{aligned}$$

# 有向图模型：贝叶斯网络

## 条件独立性

**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。



$$P(A, B) \neq P(A)P(B)$$




# 有向图模型：贝叶斯网络

## 条件独立性

**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。

head-to-tail



$A \perp B \mid C$

$$\begin{aligned} P(A, B|C) &= \frac{P(A, B, C)}{P(C)} \\ &= \frac{P(A)P(C|A)P(B|C)}{P(C)} \\ &= \frac{P(A, C)P(B|C)}{P(C)} \\ &= P(A|C)P(B|C) \end{aligned}$$

# 有向图模型：贝叶斯网络

## 条件独立性

**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。

head-to-tail



$$P(A, B) \neq P(A)P(B)$$


$$A \not\perp B$$

# 有向图模型：贝叶斯网络

## 条件独立性

**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。

head-to-head




$$P(A, B | C) \neq P(A | C)P(B | C)$$

$A \not\perp B | C$  或其任意后代

# 有向图模型：贝叶斯网络

## 条件独立性

**D-分离准则**（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。



$$\begin{aligned} P(A, B) &= \sum_C P(A, B, C) \\ &= \sum_C P(A)P(B)P(C|A, B) \\ &= P(A)P(B) \sum_C P(C|A, B) \\ &= P(A)P(B) \end{aligned}$$

# 有向图模型：贝叶斯网络

## 条件独立性

**贝叶斯网络的全局马尔科夫性**：给定结点集合  $A, B, C$ ，若  $A$  到  $B$  中结点的所有无向路径都是被  $C$  **阻塞的 (blocked)**，则称  $A$  和  $B$  被  $C$   **$D$ -分离 (D-separated)**，即  $A$  和  $B$  关于  $C$  条件独立。


若一条无向路径包含结点  $x$  满足以下条件之一，则称其是阻塞的：

- (1)  $x$  是 tail-to-tail 或 head-to-tail 结点，并且  $x$  **包含在  $C$  中**。
- (2)  $x$  是 head-to-head 结点，并且  $x$  (及  $x$  的任意后代均) **不包含在  $C$  中**。

# 有向图模型：贝叶斯网络

## 条件独立性


**例子：** A 和 B 是否关于 F 条件独立？



# 有向图模型：贝叶斯网络

## 条件独立性


**例子：** A 和 B 是否关于 F 条件独立？



# 有向图模型：贝叶斯网络

## 条件独立性

**例子：** A 和 B 是否关于 C 条件独立？






# 有向图模型：贝叶斯网络

## 条件独立性

**例子：** A 和 B 是否关于 C 条件独立？



$$A \perp\!\!\!\perp B \mid C$$

# 有向图模型：贝叶斯网络

## 条件独立性

贝叶斯网络的局部马尔科夫性：

( 1 ) 给定某变量的父结点，则该变量条件独立于所有其他非其后代结点。

$$x_v \perp x_{V \setminus \{v\} \setminus PA(v) \setminus DE(v)} \mid x_{PA(v)}$$

( 2 ) 给定某变量的马尔可夫毯（父结点，子结点，子结点的父结点），则该变量条件独立于其他变量。

$$x_v \perp x_{V \setminus \{v\} \setminus MB(v)} \mid x_{MB(v)}$$

# 第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断


9.5 实例模型

# 无向图模型：马尔可夫随机场

## 图结构：无向图

**结点**：一个或一组随机变量。

**边**：随机变量之间的相互依赖（非“因果关系”）。




# 无向图模型：马尔可夫随机场

## 图结构：无向图

**结点**：一个或一组随机变量。

**边**：随机变量之间的相互依赖（非“因果关系”）。



**团**：对于图中的结点子集，若其中任意两个节点之间都有连边，则称该结点子集为一个团（clique）。


**极大团**：若在团中加入其他任意一个结点都不再形成团，则称该团为极大团（maximal clique）。

# 无向图模型：马尔可夫随机场

## 图结构：无向图

**结点**：一个或一组随机变量。

**边**：随机变量之间的相互依赖（非“因果关系”）。



**极大团**： $\{x_1, x_2\}$ ,  $\{x_1, x_3\}$ ,  $\{x_2, x_4\}$ ,  $\{x_3, x_5\}$ ,  
 $\{x_2, x_5, x_6\}$

# 无向图模型：马尔可夫随机场

## 联合概率分布

分解形式：

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathbb{C}} \psi_C(\mathbf{x}_C)$$

其中， $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ ； $\mathbb{C}$  为团集合， $\mathbf{x}_C$  为团  $C$  对应的变量集合。

$\psi_C$  为定义在团  $C$  上的非负势函数（potential function）。

$Z$  是归一化因子：


$$Z = \sum_{\mathbf{x}} \prod_{C \in \mathbb{C}} \psi_C(\mathbf{x}_C)$$

# 无向图模型：马尔可夫随机场

## 联合概率分布

分解形式：

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathbb{C}} \psi_C(\mathbf{x}_C)$$



$$\begin{aligned} &P(x_1, x_2, x_3, x_4, x_5, x_6) \\ &= \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{13}(x_1, x_3) \psi_{24}(x_2, x_4) \\ &\quad \psi_{35}(x_3, x_5) \psi_{256}(x_2, x_5, x_6) \end{aligned}$$




# 无向图模型：马尔可夫随机场

## 示例：最简单的马尔科夫随机场

$$x_1, x_2 \in \{-1, 1\} ; C = \{x_1, x_2\} \text{ 为团} ; \psi_C(x_1, x_2) = e^{ax_1x_2}$$


$$\text{规一化因子 } Z = \sum_{x_1, x_2} \psi_C(x_1, x_2) = 2e^a + 2e^{-a}$$

$$\text{联合概率分布 } P(x_1, x_2) = \frac{1}{Z} \psi_C(x_1, x_2) = e^{ax_1x_2} / (2e^a + 2e^{-a})$$



# 无向图模型：马尔可夫随机场

## 示例：受限玻尔兹曼机




团集合： $\{\{v_i\}, \{h_j\}, \{v_i, h_j\}\}$

势函数： $\psi_V(v_i) = e^{a_i v_i}$      $\psi_H(h_j) = e^{b_j h_j}$      $\psi_{VH}(v_i, h_j) = e^{w_{ij} v_i h_j}$

# 无向图模型：马尔可夫随机场

## 示例：受限玻尔兹曼机



联合概率分布：

$$P(\mathbf{v}, \mathbf{h}) = \frac{1}{Z} \exp \left( \sum_i a_i v_i + \sum_j b_j h_j + \sum_{i,j} w_{ij} v_i h_j \right)$$


# 无向图模型：马尔可夫随机场

## 示例：图像去噪

观测图片像素点  $y_i$



原始图片像素点  $x_i$



团集合： $\{\{x_i, y_i\}, \{x_i, x_j\}\}$

势函数： $\psi_{XY}(x_i, y_i) = e^{\eta_i x_i y_i}$      $\psi_{XX}(x_i, x_j) = e^{\mu_{ij} x_i x_j}$


# 无向图模型：马尔可夫随机场

## 示例：图像去噪

观测图片像素点  $y_i$



原始图片像素点  $x_i$





联合概率分布：

$$P(\mathbf{x}, \mathbf{y}) = \frac{1}{Z} \exp \left( \sum_{i \in V} \eta_i x_i y_i + \sum_{ij \in E} \mu_{ij} x_i x_j \right)$$

# 无向图模型：马尔可夫随机场

## 条件独立性

**马尔可夫随机场的全局马尔科夫性：**给定结点集合  $A$  ,  $B$  ,  $C$  , 若从  $A$  中的结点到  $B$  中结点必须经过  $C$  中的结点，则称  $A$  和  $B$  被  $C$  分离，即  $A$  和  $B$  关于  $C$  条件独立。



# 无向图模型：马尔可夫随机场

## 条件独立性

**局部马尔科夫性**：给定某变量的马尔可夫毯（邻接变量），则该变量条件独立于其他变量。

$$x_v \perp x_{V \setminus \{v\} \setminus MB(v)} \mid x_{MB(v)}$$

**成对马尔科夫性**：给定其他所有变量，两个非相邻变量条件独立。

$$x_u \perp x_v \mid x_{V \setminus \{u,v\}} \text{ if } (u,v) \notin E$$

# 本讲参考文献

1. 《统计机器学习--第九章：概率图模型》课件，王泉，国科大网络安全学院，2017。

致谢王泉！感谢王泉提供了《概率图模型》课件供本章教学参考！