

机器学习

Machine learning

第九章 概率图模型

Probabilistic Graphical Model

授课人：周晓飞

zhouxiaofei@iie.ac.cn

2020-12-10

第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场


9.3 学习与推断

9.4 近似推断

9.5 实例模型

基本定义

推断：已知联合概率分布 $P(x_1, x_2, \dots, x_n)$ ，估计 $P(\mathbf{x}_Q | \mathbf{x}_E)$ ，其中 $\mathbf{x}_Q \cap \mathbf{x}_E = \emptyset$ ， $\mathbf{x}_Q \cup \mathbf{x}_E$ 是集合 $\{x_1, x_2, \dots, x_n\}$ 的子集。 \mathbf{x}_Q 是问题变量， \mathbf{x}_E 是证据变量。



$$P(S=1|G=1) = ?$$

$$P(R=1|G=1) = ?$$

学习与推断

基本定义

学习 : 从观测数据 $x^{(1)}, x^{(2)}, \dots, x^{(m)}$ 中学习联合概率分布 $P(x_1, x_2, \dots, x_n)$, 寻找最符合观测数据的概率图模型。

$(G, S, R) = (1, 1, 0)$

$(G, S, R) = (1, 1, 1)$

\vdots

$(G, S, R) = (1, 0, 1)$

$(G, S, R) = (0, 0, 0)$



| | | $P(R = 1)$ $P(R = 0)$ | | | | $P(G = 1)$ $P(G = 0)$ | |
|-----|-----------------------|-----------------------|-----|-----|-----|-----------------------|------|
| | | 0.2 | 0.8 | | | 0.99 | 0.01 |
| R | $P(S = 1)$ $P(S = 0)$ | | | S | R | | |
| 1 | 0.01 0.99 | | | 1 | 1 | 0.9 | 0.1 |
| 0 | 0.4 0.6 | | | 0 | 1 | 0.8 | 0.2 |
| | | | | 0 | 0 | 0.0 | 1.0 |


结构学习
(structure learning)

参数学习
(parameter learning)

已知联合概率分布 $P(x_1, x_2, \dots, x_n)$, 估计


$$P(\mathbf{x}_Q | \mathbf{x}_E) = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{P(\mathbf{x}_E)} = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{\sum_{\mathbf{x}_Q} P(\mathbf{x}_Q, \mathbf{x}_E)}$$

其中 $\mathbf{x}_Q \cap \mathbf{x}_E = \emptyset$, $\mathbf{x}_Q \cup \mathbf{x}_E = \{x_1, x_2, \dots, x_n\}$ 。




朴素贝叶斯

$$\hat{y} = \operatorname{argmax} P(y|\mathbf{x})$$



推断

已知联合概率分布 $P(x_1, x_2, \dots, x_n)$ ，估计

$$P(\mathbf{x}_Q | \mathbf{x}_E) = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{P(\mathbf{x}_E)} = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{\sum_{\mathbf{x}_Q} P(\mathbf{x}_Q, \mathbf{x}_E)}$$


核心问题

其中 $\mathbf{x}_Q \cap \mathbf{x}_E = \emptyset$ ， $\mathbf{x}_Q \cup \mathbf{x}_E = \{x_1, x_2, \dots, x_n\}$ 。

枚举：假设 \mathbf{x}_Q 有 k 个变量，每个变量的取值个数的期望是 r ，则时间复杂度为 r^k 。

推断的核心问题：如何高效地计算边际分布 $P(\mathbf{x}_E) = \sum_{\mathbf{x}_Q} P(\mathbf{x}_Q, \mathbf{x}_E)$ 。

推断方法

精确推断：计算 $P(x_E)$ 或 $P(x_Q|x_E)$ 的精确值。

- (1) 变量消去 (variable elimination)。
- (2) 信念传播 (belief propagation)。


近似推断：在较低的时间复杂度下获得原问题的近似解。

- (1) 前向采样 (forward sampling)。
- (2) 吉布斯采样 (Gibbs sampling)。

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




推断 $P(x_5) = \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1, x_2, x_3, x_4, x_5)$

$$= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) m_{12}(x_2) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3) \sum_{x_2} P(x_3|x_2)m_{12}(x_2) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3) \sum_{x_2} P(x_3|x_2)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3) \sum_{x_2} P(x_3|x_2)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) = m_{35}(x_5) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) = m_{35}(x_5) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。


无向图



$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{23}(x_2, x_3) \psi_{34}(x_3, x_4) \psi_{35}(x_3, x_5) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \frac{1}{Z} \psi_{23}(x_2, x_3) \psi_{34}(x_3, x_4) \psi_{35}(x_3, x_5) \sum_{x_1} \psi_{12}(x_1, x_2) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \frac{1}{Z} \psi_{23}(x_2, x_3) \psi_{34}(x_3, x_4) \psi_{35}(x_3, x_5) m_{12}(x_2) = \dots \end{aligned}$$

变量消去

优点：简单直观，代数上的消去对应图中结点的消去。




缺点：针对不同证据变量会造成大量冗余计算。

The diagram shows two DAGs. The left DAG has nodes x_1, x_2, x_3, x_4, x_5 with edges $x_1 \rightarrow x_2, x_2 \rightarrow x_3, x_3 \rightarrow x_4, x_3 \rightarrow x_5$. The right DAG has nodes x_1, x_2, x_3, x_4, x_5 with edges $x_1 \rightarrow x_2, x_2 \rightarrow x_3, x_3 \rightarrow x_4, x_3 \rightarrow x_5$.


$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \dots \end{aligned}$$
$$\begin{aligned} P(x_4) &= \sum_{x_5} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_5} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \dots \end{aligned}$$

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) m_{12}(x_2) \\ &= \dots \end{aligned}$$



$$\begin{aligned} P(x_4) &= \sum_{x_5} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_5} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) m_{12}(x_2) \\ &= \dots \end{aligned}$$

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





$m_{12}(x_2)$ 是从 x_1 向 x_2 传递的一条消息。

$m_{12}(x_2)$ 对 x_1 进行了求和，是关于 x_2 的函数。

$m_{12}(x_2)$ 仅与图的拓扑结构有关，与证据变量的选取无关（可复用）。

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





$m_{12}(x_2)$, $m_{23}(x_3)$ 可重复使用。

$m_{43}(x_3)$, $m_{35}(x_5)$, $m_{34}(x_4)$, $m_{53}(x_3)$ 需重新计算。

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





消息传递仅在邻接变量之间发生。

消息传递与边的方向性无关。


信念传播

树结构：有向树=无向树




信念传播

树结构：有向树=无向树



信念传播

树结构上的消息传递：



消息计算公式：（ $N(j)$ 表示 j 的邻域节点）


$$m_{ji}(x_i) = \sum_{x_j} \psi(x_i, x_j) \prod_{k \in N(j) \setminus i} m_{kj}(x_j)$$

信念传播

边际分布：

$$P(x_i) \propto \prod_{k \in N(i)} m_{ki}(x_i)$$



结点 k 对结点 i 的信念



信念传播

二次扫描算法：

- (1) 指定一个根结点，从所有叶结点开始向根节点传递消息，直到根结点收到所有邻接结点的消息。
- (2) 从根结点开始向叶结点传递消息，直到所有叶结点均收到消息。



第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断

9.5 实例模型

近似推断

推断方法

精确推断：

变量消去、信念传播。

计算复杂度随着极大团规模的增长呈指数级增长，适用范围有限。

近似推断：

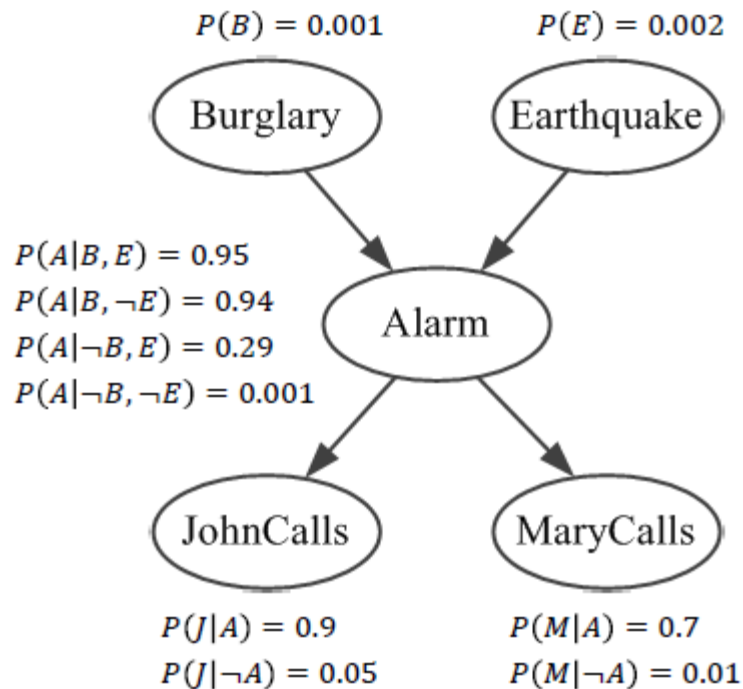
前向采样、吉布斯采样。

通过采样一组服从特定分布的样本，来近似原始分布，适用范围更广，操作性更强。

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。




$$P(B=1 | E=0, J=1) = ?$$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。



$$P(B=1 | E=0, J=1) = ?$$

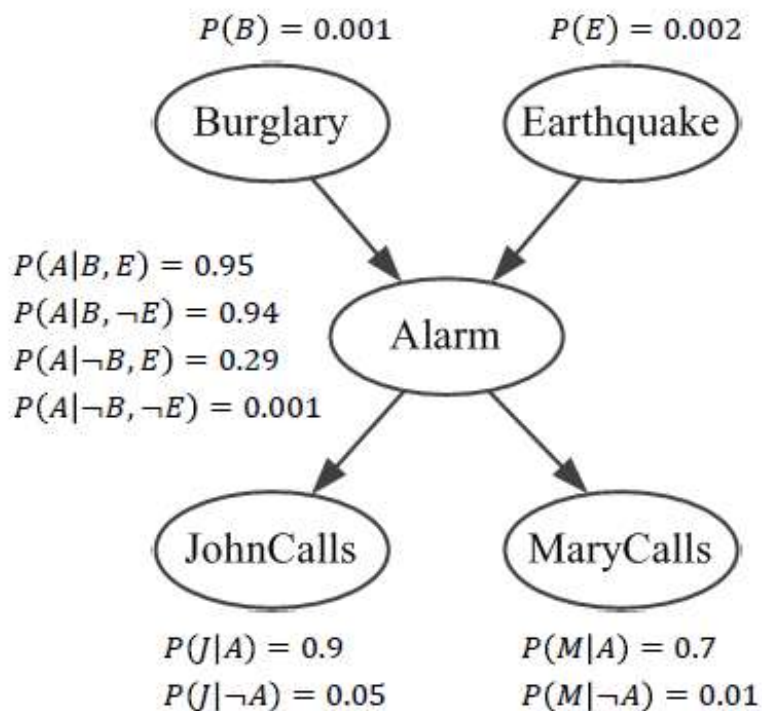
$$\begin{aligned} & P(B=1 | E=0, J=1) \\ &= \frac{P(B=1, E=0, J=1)}{P(E=0, J=1)} \\ &= \frac{\sum_{A,M} P(B=1, E=0, A, J=1, M)}{\sum_{B,A,M} P(B, E=0, A, J=1, M)} \\ &= \dots \end{aligned}$$

采样后，进行需要的概率统计！

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。

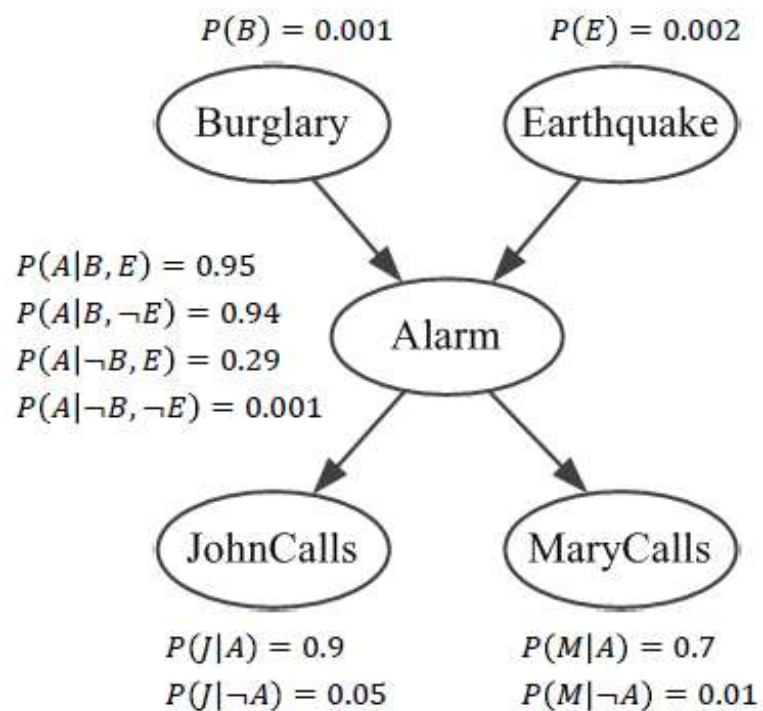


- 采样 $B \sim \text{Ber}(0.001)$
 - 采样 $r \sim U(0, 1)$: 若 $r < 0.001$, $B = 1$; 否则 $B = 0$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。

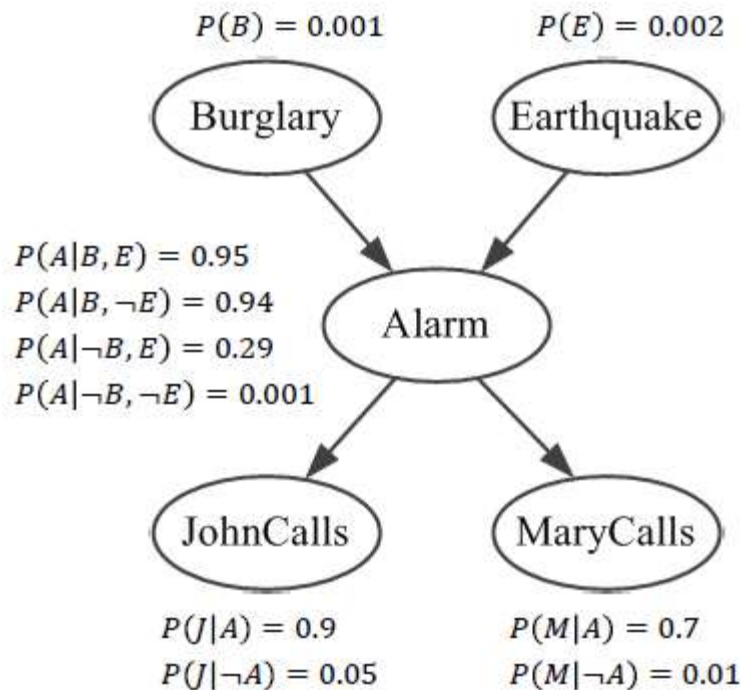


- 采样 $B \sim \text{Ber}(0.001)$
- 采样 $E \sim \text{Ber}(0.002)$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。

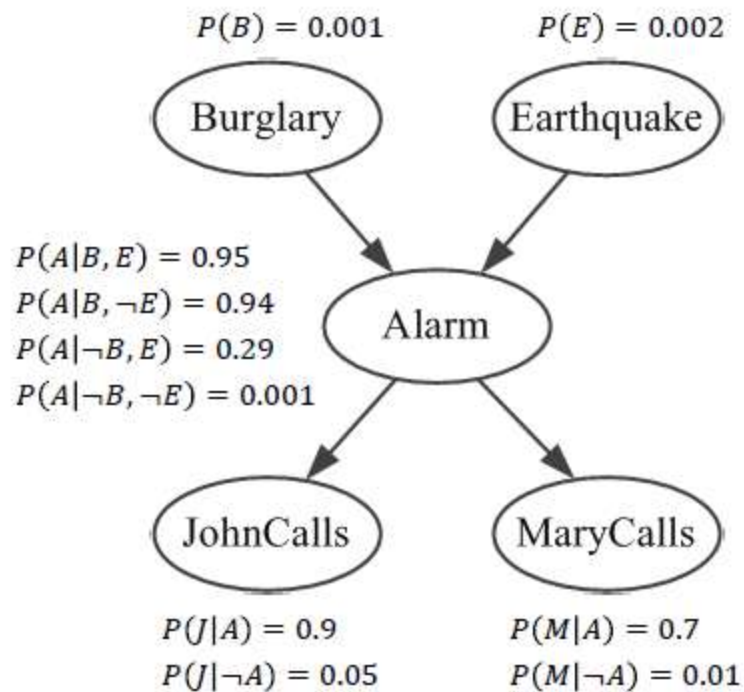


- 采样 $B \sim \text{Ber}(0.001)$
- 采样 $E \sim \text{Ber}(0.002)$
- 若 $B = 1, E = 1$, 采样 $A \sim \text{Ber}(0.95)$
若 $B = 1, E = 0$, 采样 $A \sim \text{Ber}(0.94)$
若 $B = 0, E = 1$, 采样 $A \sim \text{Ber}(0.29)$
若 $B = 0, E = 0$, 采样 $A \sim \text{Ber}(0.001)$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。

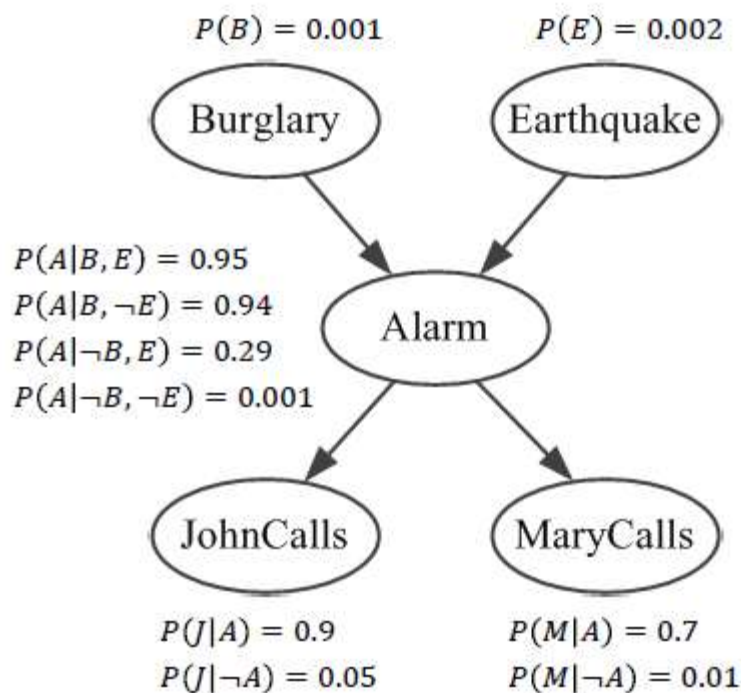


- 采样 $B \sim \text{Ber}(0.001)$
- 采样 $E \sim \text{Ber}(0.002)$
- 若 $B = 1, E = 1$, 采样 $A \sim \text{Ber}(0.95)$
若 $B = 1, E = 0$, 采样 $A \sim \text{Ber}(0.94)$
若 $B = 0, E = 1$, 采样 $A \sim \text{Ber}(0.29)$
若 $B = 0, E = 0$, 采样 $A \sim \text{Ber}(0.001)$
- 若 $A = 1$, 采样 $J \sim \text{Ber}(0.9)$; 否则采样 $J \sim \text{Ber}(0.05)$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。

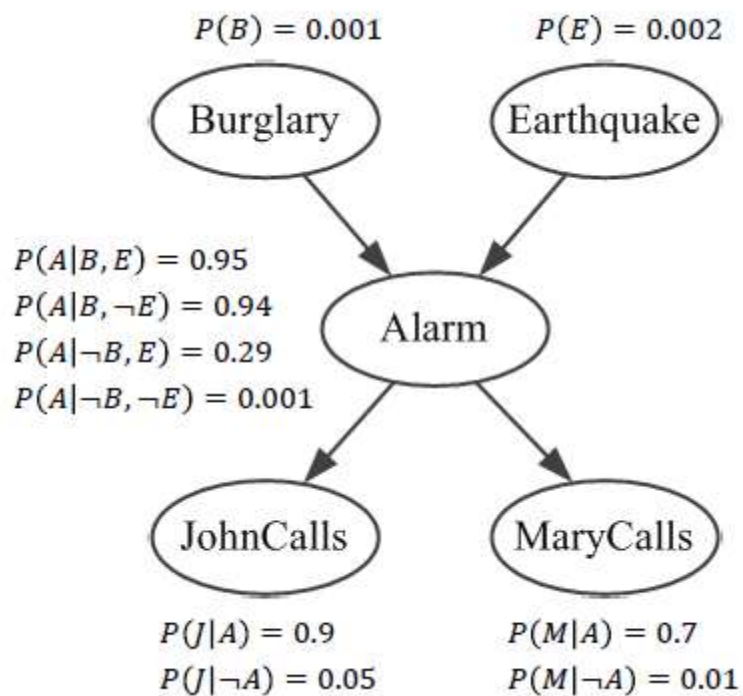


- 采样 $B \sim \text{Ber}(0.001)$
- 采样 $E \sim \text{Ber}(0.002)$
- 若 $B = 1, E = 1$, 采样 $A \sim \text{Ber}(0.95)$
若 $B = 1, E = 0$, 采样 $A \sim \text{Ber}(0.94)$
若 $B = 0, E = 1$, 采样 $A \sim \text{Ber}(0.29)$
若 $B = 0, E = 0$, 采样 $A \sim \text{Ber}(0.001)$
- 若 $A = 1$, 采样 $J \sim \text{Ber}(0.9)$; 否则采样 $J \sim \text{Ber}(0.05)$
- 若 $A = 1$, 采样 $M \sim \text{Ber}(0.7)$; 否则采样 $M \sim \text{Ber}(0.01)$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。



| B | E | A | J | M |
|-----|-----|-----|-----|-----|
| 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 1 | 1 | 0 |
| 0 | 0 | 0 | 0 | 1 |
| 0 | 0 | 0 | 0 | 0 |
| 0 | 0 | 0 | 0 | 0 |
| 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 1 | 1 | 1 |
| 0 | 0 | 0 | 0 | 0 |
| 0 | 0 | 1 | 1 | 0 |
| 0 | 0 | 0 | 0 | 0 |

前向采样

```
graph TD; B(Burglary) --> A(Alarm); E(Earthquake) --> A; A --> J(JohnCalls); A --> M(MaryCalls);
```

$P(B) = 0.001$
 $P(E) = 0.002$
 $P(A|B, E) = 0.95$
 $P(A|B, \neg E) = 0.94$
 $P(A|\neg B, E) = 0.29$
 $P(A|\neg B, \neg E) = 0.001$
 $P(J|A) = 0.9$
 $P(J|\neg A) = 0.05$
 $P(M|A) = 0.7$
 $P(M|\neg A) = 0.01$

| B | E | A | J | M |
|-----|-----|-----|-----|-----|
| 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 1 | 1 | 0 |
| 0 | 0 | 0 | 0 | 1 |
| 0 | 0 | 0 | 0 | 0 |
| 0 | 0 | 0 | 0 | 0 |
| 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 1 | 1 | 1 |
| 0 | 0 | 0 | 0 | 0 |
| 0 | 0 | 1 | 1 | 0 |
| 0 | 0 | 0 | 0 | 0 |

$$P(B = 1|E = 0, J = 1) = 2/3$$

近似推断

前向采样

思路：依据贝叶斯网络的（条件）概率直接采样。

缺点：I) 对于小概率事件采样困难，可能经过很多次采样也无法获得足够多的样本；

II) 仅适用于贝叶斯网络，不适用于马尔可夫随机场。

近似推断

吉布斯采样

思路：直接依照条件概率 $P(\mathbf{x}_Q|\mathbf{x}_E)$ 采样。

Procedure Gibbs Sampling

- 1 Fix \mathbf{x}_E and randomly initialize other variables $\mathbf{x}_O := \{x_1, \dots, x_n\} \setminus \mathbf{x}_E$
 - 2 **repeat**
 - 3 **foreach** $x_i \in \mathbf{x}_O$ **do**
 - 4 Sample $x \sim P(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$ /* x_i 在其他所有变量当前取值下的条件概率 */
 - 5 $x_i \leftarrow x$
 - 6 **until** Convergence
 - 7 **return** The later samples
-

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。


马尔可夫毯的性质：

$$P(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(x_i | MB(x_i))$$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。




$$P(B = 1 | E = 1, M = 1) = ?$$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。

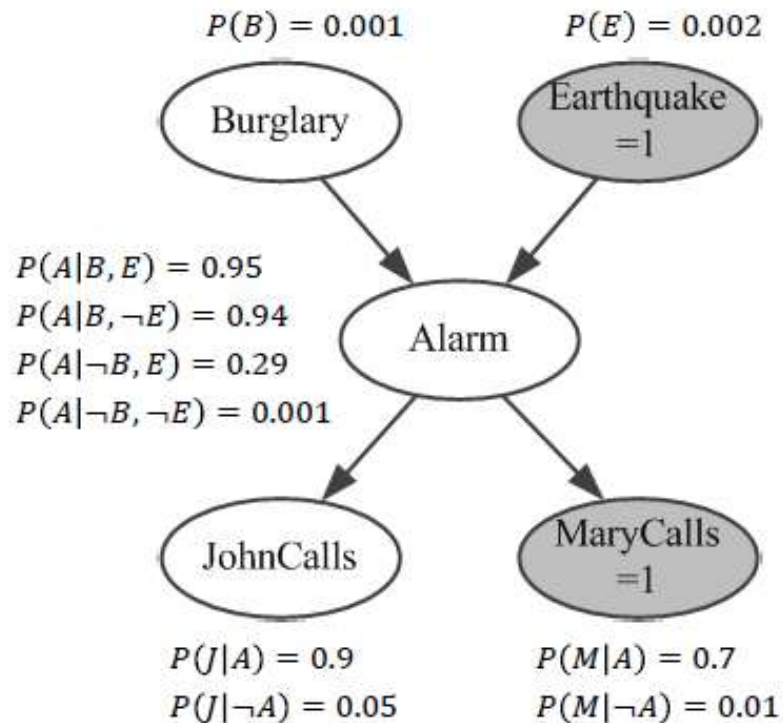


| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | | | | | |

- 采样 B ，马尔可夫毯 $\{A, E\}$


$$P(B|\neg A, E) \propto P(B)P(\neg A|B, E) = 0.001 \times 0.05$$

$$P(\neg B|\neg A, E) \propto P(\neg B)P(\neg A|\neg B, E) = 0.999 \times 0.71$$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | | | | |

- 采样 B ，马尔可夫毯 $\{A, E\}$

$$P(B|\neg A, E) \propto P(B)P(\neg A|B, E) = 0.001 \times 0.05$$


$$P(\neg B|\neg A, E) \propto P(\neg B)P(\neg A|\neg B, E) = 0.999 \times 0.71$$

- 采得 $B = 0$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。




| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | | | |

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | | | |

- 采样 A , 马尔可夫毯 $\{B, E, J, M\}$


$$P(A|\neg B, E, \neg J, M) \propto P(A|\neg B, E)P(\neg J|A)P(M|A) \\ = 0.29 \times 0.1 \times 0.7$$

$$P(\neg A|\neg B, E, \neg J, M) \propto P(\neg A|\neg B, E)P(\neg J|\neg A)P(M|\neg A) \\ = 0.71 \times 0.95 \times 0.01$$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | 1 | | |

- 采样 A ，马尔可夫毯 $\{B, E, J, M\}$

$$P(A|\neg B, E, \neg J, M) \propto P(A|\neg B, E)P(\neg J|A)P(M|A) \\ = 0.29 \times 0.1 \times 0.7$$


$$P(\neg A|\neg B, E, \neg J, M) \propto P(\neg A|\neg B, E)P(\neg J|\neg A)P(M|\neg A) \\ = 0.71 \times 0.95 \times 0.01$$

- 采得 $A = 1$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | 1 | | |

- 采样 J , 马尔可夫毯 $\{A\}$


$$P(J|A) = 0.9$$

$$P(\neg J|A) = 0.1$$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | 1 | 1 | |

- 采样 J , 马尔可夫毯 $\{A\}$

$$P(J|A) = 0.9$$


$$P(\neg J|A) = 0.1$$

- 采得 $J = 1$

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。

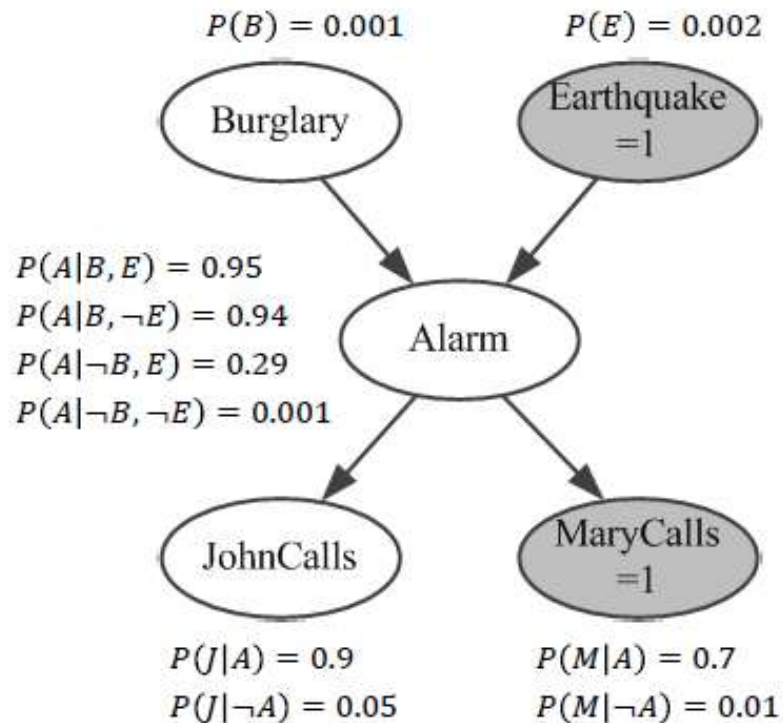


| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | 1 | 1 | 1 |

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。



| Iteration | B | E | A | J | M |
|-----------|-----|-----|-----|-----|-----|
| $t = 0$ | 0 | 1 | 0 | 0 | 1 |
| $t = 1$ | 0 | 1 | 1 | 1 | 1 |
| $t = 2$ | 0 | 1 | 0 | 1 | 1 |
| $t = 3$ | 1 | 1 | 1 | 1 | 1 |

近似推断

吉布斯采样

思路：直接依照条件概率 $P(x_Q|x_E)$ 采样。

优点：I) 直接从 $P(x_Q|x_E)$ 采样，解决小概率事件采样难的问题； (Fixed x_E)

II) 同时适用于贝叶斯网络和马尔可夫随机场；

III) 简单易推导，时间复杂度低。

本讲参考文献

1. 《统计机器学习--第九章：概率图模型》课件，王泉，国科大网络安全学院，2017。

致谢王泉副研究员！感谢王泉提供了《概率图模型》课件供本章教学参考！