

机器学习

Machine learning

第九章 概率图模型

Probabilistic Graphical Model

授课人：周晓飞

zhouxiaofei@iie.ac.cn

2020-12-12

第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断

9.5 实例模型

实例模型


隐马尔可夫模型

条件随机场

隐马尔可夫模型

HMM 模型定义

隐马尔可夫模型是关于时序的概率模型，是最简单的动态贝叶斯网络模型。




状态变量 $\{y_1, y_2, \dots, y_n\}$, $y_t \in Y$ 表示第 t 时刻的系统状态 ,

隐马尔可夫模型

HMM 模型定义

隐马尔可夫模型是关于时序的概率模型，是最简单的动态贝叶斯网络模型。




状态变量 $\{y_1, y_2, \dots, y_n\}$, $y_t \in Y$ 表示第 t 时刻的系统状态，

观测变量 $\{x_1, x_2, \dots, x_n\}$, $x_t \in X$ 表示第 t 时刻的观测值。

隐马尔可夫模型

HMM 模型定义

隐马尔可夫模型是关于时序的概率模型，是最简单的动态贝叶斯网络模型。



状态变量 $\{y_1, y_2, \dots, y_n\}$, $y_t \in Y$ 表示第 t 时刻的系统状态，

观测变量 $\{x_1, x_2, \dots, x_n\}$, $x_t \in X$ 表示第 t 时刻的观测值。


观测变量仅依赖于当前时刻的状态变量，当前状态仅依赖于前一时刻的状态。

状态集合 $Y = \{s_1, s_2, \dots, s_N\}$, 观测值集合 $X = \{o_1, o_2, \dots, o_M\}$ 。

隐马尔可夫模型

HMM 模型定义

联合概率



$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1)P(x_1 | y_1) \prod_{t=2}^n P(x_t | y_t)P(y_t | y_{t-1})$$


隐马尔可夫模型

HMM 模型参数

状态转移矩阵 $A=[a_{ij}]_{N \times N}$

$$a_{ij} = P(y_{t+1} = s_j \mid y_t = s_i) \quad 1 \leq i, j \leq N$$

表示 t 时刻处于状态 s_i 的条件下, $t+1$ 时刻转移到状态 s_j 的概率。




隐马尔可夫模型

HMM 模型参数

观测概率矩阵 $B=[b_{ij}]_{N \times M}$

$$b_{ij} = P(x_t = o_j | y_t = s_i) \quad 1 \leq i \leq N, \quad 1 \leq j \leq M$$

表示 t 时刻处于状态 s_i 的条件下观测到 o_j 的概率。




隐马尔可夫模型

HMM 模型参数

初始状态概率向量 $\pi = (\pi_1, \pi_2, \dots, \pi_N)$

$$\pi_i = P(y_1 = s_i) \quad 1 \leq i \leq N$$

表示系统初始状态为 s_i 概率。




隐马尔可夫模型

HMM 模型参数

初始状态概率向量 $\pi = (\pi_1, \pi_2, \dots, \pi_N)$

$$\pi_i = P(y_1 = s_i) \quad 1 \leq i \leq N$$

表示系统初始状态为 s_i 概率。




隐马尔可夫模型由 A , B , π 唯一确定 , A , B , π 称为隐马尔可夫模型的三要素。

隐马尔可夫模型

生成过程


给定 A , B , π , 生成观测序列 $\{x_1, x_2, \dots, x_n\}$ 。



隐马尔可夫模型

生成过程

给定 A , B , π , 生成观测序列 $\{x_1, x_2, \dots, x_n\}$ 。




(1) 设置 $t=1$, 并根据初始状态概率 π 生成初始状态 y_1 。

隐马尔可夫模型

生成过程

给定 A , B , π , 生成观测序列 $\{x_1, x_2, \dots, x_n\}$ 。




- (1) 设置 $t=1$, 并根据初始状态概率 π 生成初始状态 y_1 。
- (2) 根据 y_t 和观测概率矩阵 B 生成 x_t 。

隐马尔可夫模型

生成过程

给定 A , B , π , 生成观测序列 $\{x_1, x_2, \dots, x_n\}$ 。




- (1) 设置 $t=1$, 并根据初始状态概率 π 生成初始状态 y_1 。
- (2) 根据 y_t 和观测概率矩阵 B 生成 x_t 。
- (3) 根据 y_t 和状态转移矩阵 A 生成 y_{t+1} 。

隐马尔可夫模型

生成过程

给定 A , B , π , 生成观测序列 $\{x_1, x_2, \dots, x_n\}$ 。



- (1) 设置 $t=1$, 并根据初始状态概率 π 生成初始状态 y_1 。
- (2) 根据 y_t 和观测概率矩阵 B 生成 x_t 。
- (3) 根据 y_t 和状态转移矩阵 A 生成 y_{t+1} 。
- (4) 若 $t < n$, 则设置 $t=t+1$, 并转到第 (2) 步 ; 否则 , 停止。

隐马尔可夫模型

三个基本问题

概率计算问题：给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$ 计算在模型 λ 下观测到 \mathbf{x} 的概率 $P(\mathbf{x} | \lambda)$ 。(评估模型与观测序列之间的匹配程度)

隐马尔可夫模型

三个基本问题

概率计算问题：给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$ 计算在模型 λ 下观测到 \mathbf{x} 的概率 $P(\mathbf{x} | \lambda)$ 。(评估模型与观测序列之间的匹配程度)

预测问题：给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$, 求使得条件概率 $P(\mathbf{y} | \mathbf{x}, \lambda)$ 最大的状态观测序列 $\mathbf{y} = \{y_1, \dots, y_n\}$ 。(根据观测序列推测状态序列)

隐马尔可夫模型

三个基本问题

概率计算问题：给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$ 计算在模型 λ 下观测到 \mathbf{x} 的概率 $P(\mathbf{x} | \lambda)$ 。(评估模型与观测序列之间的匹配程度)

预测问题：给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$, 求使得条件概率 $P(\mathbf{y} | \mathbf{x}, \lambda)$ 最大的状态观测序列 $\mathbf{y} = \{y_1, \dots, y_n\}$ 。(根据观测序列推测状态序列)

学习问题：给定观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$, 调整模型 $\lambda = (A, B, \pi)$ 参数 , 使得该序列出现的概率 $P(\mathbf{x} | \lambda)$ 最大。(训练模型使其更好地描述观测序列)

隐马尔可夫模型

概率计算问题

给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$ 计算在模型 λ 下观测到 \mathbf{x} 的概率 $P(\mathbf{x} | \lambda)$ 。

(评估模型与观测序列之间的匹配程度)

直接算法

$$\Pr(\mathbf{x} | \lambda) = \sum_{\mathbf{y}} \Pr(\mathbf{x}, \mathbf{y} | \lambda) = \sum_{\mathbf{y}} \Pr(\mathbf{x} | \mathbf{y}, \lambda) \Pr(\mathbf{y} | \lambda)$$

前向后向算法

隐马尔可夫模型

直接计算法

(1) 列举所有可能的长度为 n 的状态序列 $\mathbf{y} = \{y_1, \dots, y_n\}$ 。

$$\Pr(\mathbf{y}|\lambda) = \pi_{y_1} a_{y_1 y_2} a_{y_2 y_3} \cdots a_{y_{n-1} y_n}$$

(2) 求各状态序列 \mathbf{y} 与观测序列 \mathbf{x} 的联合概率 $P(\mathbf{x}, \mathbf{y} | \lambda)$ 。

$$\Pr(\mathbf{x}|\mathbf{y}, \lambda) = b_{y_1}(x_1) b_{y_2}(x_2) \cdots b_{y_n}(x_n)$$

$$\Pr(\mathbf{x}, \mathbf{y}|\lambda) = \Pr(\mathbf{x}|\mathbf{y}, \lambda) \Pr(\mathbf{y}|\lambda) = \pi_{y_1} b_{y_1}(x_1) a_{y_1 y_2} b_{y_2}(x_2) \cdots a_{y_{n-1} y_n} b_{y_n}(x_n)$$

(3) 对所有的状态序列 $\mathbf{y} = \{y_1, \dots, y_n\}$ 求和，得到 $P(\mathbf{x} | \lambda)$ 。

$$\Pr(\mathbf{x}|\lambda) = \sum_{\mathbf{y}} \Pr(\mathbf{x}, \mathbf{y}|\lambda) = \sum_{y_1, y_2, \dots, y_n} \pi_{y_1} b_{y_1}(x_1) a_{y_1 y_2} b_{y_2}(x_2) \cdots a_{y_{n-1} y_n} b_{y_n}(x_n)$$


计算复杂度 $O(nN^n)$ (每条路径有 $2n$ 个乘法操作，共 N^n 个路径)

隐马尔可夫模型

前向算法

前向概率： 给定隐马尔可夫模型 $\lambda = (A, B, \pi)$, 定义到时间 t 的部分观测序列为 x_1, x_2, \dots, x_t 并且状态为 s_i 的概率为前向概率 , 记作


$$\alpha_t(i) = \Pr(x_1, x_2, \dots, x_t, y_t = s_i \mid \lambda)$$



隐马尔可夫模型

前向算法



前向概率递推公式：



隐马尔可夫模型

前向算法

前向概率递推公式：



$$\begin{aligned}\alpha_{t+1}(i) &= b_i(x_{t+1}) \sum_j \Pr(x_1, x_2, \dots, x_t, y_t = s_j | \lambda) \Pr(y_{t+1} = s_i | y_t = s_j, \lambda) \\ &= b_i(x_{t+1}) \sum_j \alpha_t(j) a_{ji}, \quad i = 1, 2, \dots, N.\end{aligned}$$

隐马尔可夫模型

前向算法

Algorithm 1 观测序列概率的前向算法

Input: 隐马尔可夫模型 $\lambda = [\mathbf{A}, \mathbf{B}, \boldsymbol{\pi}]$, 观测序列 $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$

1: 初始化前向概率 $\alpha_1(i) = \pi_i b_i(x_1)$, $i = 1, 2, \dots, N$

2: **for** $t = 1 : (n - 1)$ **do**

3: 递推计算前向概率 $\alpha_{t+1}(i) = b_i(x_{t+1}) \sum_{j=1}^N \alpha_t(j) a_{ji}$, $i = 1, 2, \dots, N$

4: **end for**

Output: 观测序列概率 $\Pr(\mathbf{x}|\lambda) = \sum_{i=1}^N \Pr(\mathbf{x}, y_n = s_i|\lambda) = \sum_{i=1}^N \alpha_n(i)$

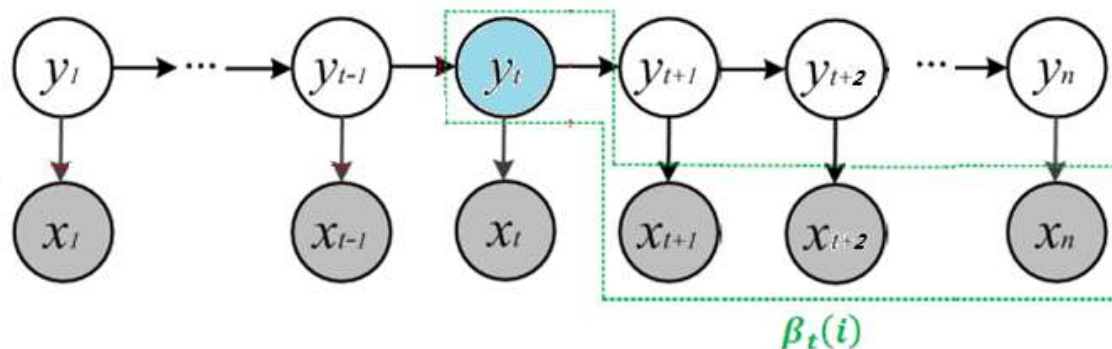
计算复杂度 $O(nN^2)$ （每层有 $N^2 + N$ 个乘操作，共 n 层）

隐马尔可夫模型

后向算法

后向概率： 给定隐马尔可夫模型 $\lambda = (A, B, \pi)$ ，定义时间 t 状态为 s_i 的条件下，从 $t+1$ 时刻到 n 时刻的部分观测序列为 $x_{t+1}, x_{t+2}, \dots, x_n$ 的概率为后向概率，记作


$$\beta_t(i) = \Pr(x_{t+1}, x_{t+2}, \dots, x_n \mid y_t = s_i, \lambda)$$



隐马尔可夫模型


后向算法

后向概率递推公式：




隐马尔可夫模型

后向算法



$$\begin{aligned}\beta_t(i) &= \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_t = s_i, \lambda) \\ &= \sum_j \Pr(x_{t+1}, x_{t+2}, \dots, x_n, y_{t+1} = s_j | y_t = s_i, \lambda) \\ &= \sum_j \Pr(y_{t+1} = s_j | y_t = s_i, \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_{t+1} = s_j, y_t = s_i, \lambda) \\ &= \sum_j \Pr(y_{t+1} = s_j | y_t = s_i, \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_{t+1} = s_j, \lambda) \\ &= \sum_j a_{ij} \Pr(x_{t+1} | y_{t+1} = s_j, \lambda) \Pr(x_{t+2}, \dots, x_n | y_{t+1} = s_j, \lambda) \\ &= \sum_j a_{ij} b_j(x_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N.\end{aligned}$$

y_t 与 x_{t+1}, \dots, x_n 无关



隐马尔可夫模型

后向算法

Algorithm 2 观测序列概率的后向算法

Input: 隐马尔可夫模型 $\lambda = [\mathbf{A}, \mathbf{B}, \boldsymbol{\pi}]$, 观测序列 $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$

1: 初始化后向概率 $\beta_n(i) = 1, \quad i = 1, 2, \dots, N$

2: **for** $t = (n - 1) : 1$ **do**

3: 递推计算后向概率 $\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(x_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N$

4: **end for**

Output: 观测序列概率 $\Pr(\mathbf{x}|\lambda) = \sum_{i=1}^N \pi_i b_i(x_1) \beta_1(i)$

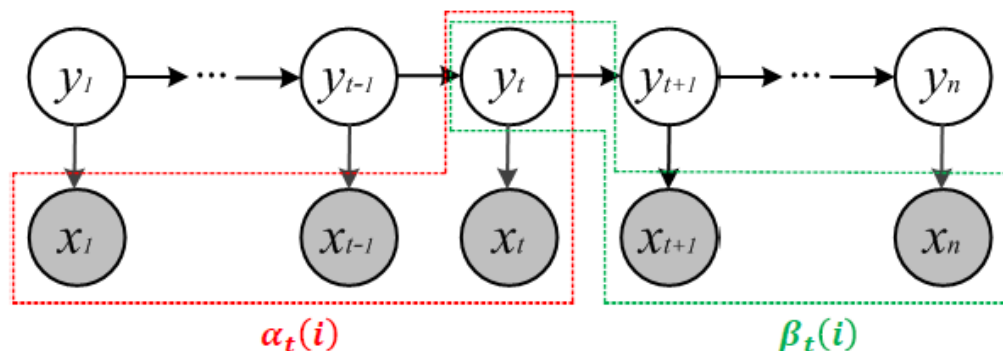
计算复杂度 $O(nN^2)$ （每层有 $N^2 + N$ 个乘操作，共 n 层）

隐马尔可夫模型

前向-后向算法

利用前向和后向概率，可以将观测概率统一写成

$$\Pr(\mathbf{x} | \lambda) = \sum_{i=1}^N \alpha_t(i) \beta_t(i), \quad t = 1, 2, \dots, n$$



$$\begin{aligned} \alpha_t(i) \beta_t(i) &= \Pr(x_1, x_2, \dots, x_t, y_t = s_i | \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_t = s_i, \lambda) \\ &= \Pr(x_1, x_2, \dots, x_t, y_t = s_i | \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_t = s_i, \boxed{x_1, x_2, \dots, x_t}, \lambda) \\ &= \Pr(x_1, x_2, \dots, x_t, x_{t+1}, x_{t+2}, \dots, x_n, y_t = s_i | \lambda) \end{aligned}$$

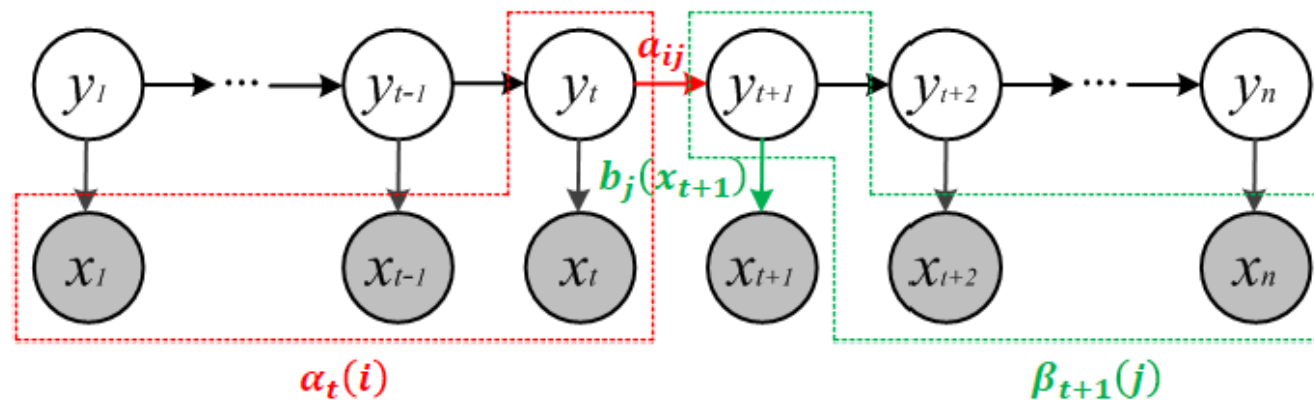
与 x_{t+1}, \dots, x_n 无关

隐马尔可夫模型

前向-后向算法

利用前向和后向概率，也可以将观测概率统一写成

$$\Pr(\mathbf{x} | \lambda) = \sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(i), \quad t = 1, 2, \dots, n-1$$




隐马尔可夫模型

相关概率和期望的计算

给定隐马尔可夫模型 $\lambda = (A, B, \pi)$ 和观测序列 \mathbf{x} ，在时刻 t 处于状态 s_i 的概率：

$$\gamma_t(i) = \Pr(y_t = s_i | \mathbf{x}, \lambda) = \frac{\Pr(y_t = s_i, \mathbf{x} | \lambda)}{\Pr(\mathbf{x} | \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$

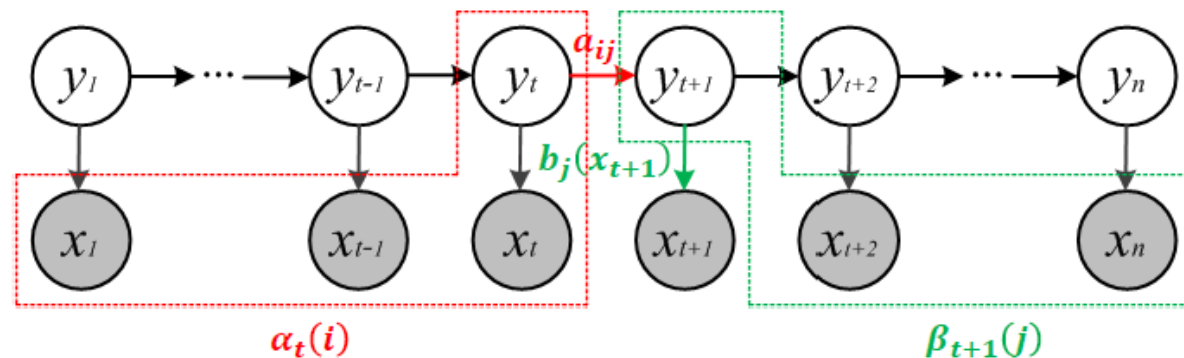


隐马尔可夫模型

相关概率和期望的计算

给定隐马尔可夫模型 $\lambda = (A, B, \pi)$ 和观测序列 \mathbf{x} , 在时刻 t 处于状态 s_i 并且在时刻 $t+1$ 处于状态 s_j 的概率:

$$\begin{aligned}\xi_t(i, j) &= \Pr(y_t = s_i, y_{t+1} = s_j | \mathbf{x}, \lambda) = \frac{\Pr(y_t = s_i, y_{t+1} = s_j, \mathbf{x} | \lambda)}{\Pr(\mathbf{x} | \lambda)} \\ &= \frac{\alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)}.\end{aligned}$$



隐马尔可夫模型

相关概率和期望的计算

在观测 \mathbf{x} 下状态 s_i 出现的期望值 (所有时刻 i 出现上的期望和):

$$\sum_{t=1}^n \gamma_t(i)$$

在观测 \mathbf{x} 下由状态 s_i 转移的期望值 (所有时刻 i 移出的期望和):

$$\sum_{t=1}^{n-1} \gamma_t(i)$$

在观测 \mathbf{x} 下由状态 s_i 转移到状态 s_j 的期望值 (所有时刻 i 转移 j 的期望和):

$$\sum_{t=1}^{n-1} \xi_t(i, j)$$

隐马尔可夫模型

预测问题

给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$, 求使得条件概率 $P(\mathbf{y} | \mathbf{x}, \lambda)$ 最大的状态观测序列 $\mathbf{y} = \{y_1, \dots, y_n\}$, 即根据观测序列推测状态序列。

贪婪算法 (精确算法) : 找最大值路径

比较每条 y 路径的 $\Pr(\mathbf{x}, \mathbf{y} | \lambda)$

近似算法

维特比算法 (精确算法)

隐马尔可夫模型

近似算法

思路： 在每个时刻 t 选择最有可能出现的状态 y_t^* ，得到一个状态序列 $\mathbf{y}^* = \{y_1^*, y_2^*, \dots, y_n^*\}$ ，将这作为预测结果。

$$\begin{aligned} y_t^* &= \arg \max_{1 \leq i \leq N} \Pr(y_t = s_i | \mathbf{x}, \lambda) \\ &= \arg \max_{1 \leq i \leq N} \gamma_t(i) = \arg \max_{1 \leq i \leq N} \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}, \quad t = 1, 2, \dots, n \end{aligned}$$

优点： 计算简单，但不能保证预测结果是合法的（ $a_{ij}=0$ ）。

隐马尔可夫模型

维特比算法

思路：利用动态规划求解概率最大路径，这里一条路径对应着一个状态序列。

如果最优路径 y^* 在 t 时刻通过结点 y_t^* ，那么这条路径从起始结点到结点 y_t^* 的路径中，**局部路径 $y_{1:t}^* (y_1^* \sim y_t^*)$ 一定是最优的。**

假定从起始时刻到 t 时刻上各个状态的最优路径已经找到，那么在计算从起始时刻到 $t+1$ 时刻上的某个状态 s_j 的最优路径时，只需要考虑从起始时刻到上一时刻所有 N 个状态 s_i 的最优路径，以及从 s_i 到 s_j 的“距离”。

隐马尔可夫模型

维特比算法

维特比变量：在时刻 t ，隐马尔可夫模型沿着一条路径到达状态 s_i ，并输出观测序列

$\mathbf{x} = \{x_1, \dots, x_n\}$ 的最大概率。

$$\delta_t(i) = \max_{y_1, y_2, \dots, y_{t-1}} \Pr(y_t = s_i, y_{t-1}, \dots, y_1, x_t, x_{t-1}, \dots, x_1 | \lambda)$$

$$\delta_1(i) = \pi_i b_i(x_1) \quad \delta_t(i) = \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t), \quad t = 2, 3, \dots, n$$

路径变量：记录该路径上状态 s_i 的前一个状态。

$$\phi_t(i) = \arg \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t), \quad t = 2, 3, \dots, n$$

隐马尔可夫模型

维特比算法

Algorithm 3 维特比算法

Input: 隐马尔可夫模型 $\lambda = [A, B, \pi]$, 观测序列 $x = \{x_1, x_2, \dots, x_n\}$

- 1: 初始化: $\delta_1(i) = \pi_i b_i(x_1)$, $\phi_1(i) = 0$, $i = 1, 2, \dots, N$
- 2: for $t = 2 : n$ do
- 3: 递推计算: $\delta_t(i) = \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t)$, $i = 1, 2, \dots, N$
- 4: 记忆路径: $\phi_t(i) = \arg \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t)$, $i = 1, 2, \dots, N$
- 5: end for
- 6: 终结: $P^* = \max_{1 \leq i \leq N} \delta_n(i)$, $y_n^* = \arg \max_{1 \leq i \leq N} \delta_n(i)$
- 7: for $t = (n - 1) : 1$ do
- 8: 回溯最优路径: $y_t^* = \phi_{t+1}(y_{t+1}^*)$
- 9: end for

Output: 最优状态序列 $y^* = \{y_1^*, y_2^*, \dots, y_n^*\}$

计算复杂度 $O(nN^2)$ (每层都是 N^2+N 个乘法, 共 n 层)

隐马尔可夫模型

学习问题

给定观测序列 $\mathbf{x} = \{x_1, \dots, x_n\}$, 调整模型 $\lambda = (A, B, \pi)$ 参数 , 使得该序列出现的概率 $P(\mathbf{x} | \lambda)$ 最大 , 即训练模型使其更好地描述观测序列。

监督学习方法

非监督学习方法 (Baum-Welch 算法)

隐马尔可夫模型

监督学习方法

训练数据包含 S 个长度相同的观测序列和对应的状态序列 $\{ (x_1, y_1), (x_2, y_2), \dots, (x_s, y_s) \}$,
利用极大似然法估计隐马尔可夫模型的参数。 ($P(X,Y)$ 最大似然估计)

状态转移概率： $\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}$, A_{ij} 是由状态 s_i 转移到 s_j 的频数。

输出观测概率： $\hat{b}_{ik} = \frac{B_{ik}}{\sum_{k=1}^M B_{ik}}$, B_{ik} 是由状态 s_i 观测到 o_k 的频数。

初始状态概率： $\hat{\pi}_i$ 为所有 S 个样本中初始状态为 s_i 的频率。

隐马尔可夫模型

非监督学习方法

训练数据只包含 S 个长度相同的观测序列 $\{x_1, x_2, \dots, x_S\}$ 而没有对应的状态序列。


将观测序列看作观测数据 x ，状态序列看作不可观测的隐数据 y ，隐马尔可夫模型等价于含有隐变量的概率模型。

$$P(x|\lambda) = \sum_y P(x|y, \lambda)P(y|\lambda)$$

相应的参数学习可以由EM算法实现。（《统计学习方法》李航，P 181页）

隐马尔可夫模型


示例：信封问题



- (1) 开始等概率选择一个信封，并从中随机抽取出一个球，记录其颜色然后放回。
- (2) 再次选择一个信封，其规则是如果上次选择的是第一个信封，则本次选第二个信封；否则等概率随机选择。
- (3) 确定信封后，从中随机抽取出一个球，记录其颜色然后放回。
- (4) 重复上述过程 5 次得到观测序列{红，黑，黑，黑，红}。

隐马尔可夫模型

示例：信封问题



状态变量：信封序列 $\{E_1, E_2, E_3, E_4, E_5\}$ （不可观测）

观测变量：球的颜色序列 $\{B_1=\text{红}, B_2=\text{黑}, B_3=\text{黑}, B_4=\text{黑}, B_5=\text{红}\}$

状态集合 $\{0, 1\}$ ，观测集合 $\{\text{红}, \text{黑}\}$

$$\pi = (0.5, 0.5) \quad \mathbf{A} = \begin{bmatrix} 0 & 1 \\ 0.5 & 0.5 \end{bmatrix} \quad \mathbf{B} = \begin{bmatrix} 0.5 & 0.5 \\ 0 & 1 \end{bmatrix}$$


隐马尔可夫模型

条件随机场

条件随机场

CRF 模型定义

条件随机场(Conditional Random Field) 是给定随机变量 \mathbf{x} 的条件下，随机变量 \mathbf{y} 的马尔可夫随机场。 $G(V, E)$ 是 \mathbf{y} 中的随机变量构成的无向图，图中每个变量在给定 \mathbf{x} 的条件下都满足马尔可夫性：




$$P(y_v | \mathbf{x}, \mathbf{y}_{V \setminus \{v\}}) = P(y_v | \mathbf{x}, \mathbf{y}_{MB(v)})$$

$\mathbf{y}_{MB(v)}$ 是 y_v 的邻接变量.

条件随机场

线性链条件随机场

线性链条件随机场(linear-chain CRF) 是随机变量 y 为线性链时的条件随机场。



$\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ 是观测序列。 $\mathbf{y} = \{y_1, y_2, \dots, y_n\}$ 是标记序列（或称状态序列）。


在给定 \mathbf{x} 的条件下， \mathbf{y} 的条件分布 $P(\mathbf{y}|\mathbf{x})$ 构成条件随机场。

$$P(y_i|\mathbf{x}, y_1, \dots, y_{i-1}, y_{i+1}, \dots, y_n) = P(y_i|\mathbf{x}, y_{i-1}, y_{i+1})$$

条件随机场

线性链条件随机场

线性链条件随机场(linear-chain CRF) 是随机变量 \mathbf{y} 为线性链时的条件随机场。



$$P(\mathbf{y} | \mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{i,j} \lambda_j t_j(y_{i+1}, y_i, \mathbf{x}, i) + \sum_{i,k} \mu_k s_k(y_i, \mathbf{x}, i) \right)$$

转移特征函数： $t_j(y_i, y_{i+1}, \mathbf{x}, i)$ 团 $\{y_i, y_{i+1}\}$ 上的势函数： $\sum_j \lambda_j t_j(y_i, y_{i+1}, \mathbf{x}, i)$

状态特征函数： $s_k(y_i, \mathbf{x}, i)$ 团 $\{y_i\}$ 上的势函数： $\sum_k \mu_k s_k(y_i, \mathbf{x}, i)$

条件随机场

三个基本问题

概率计算问题： 给定条件随机场、观测序列 $\mathbf{x}=x_1,\cdots,x_n$ 和状态序列 $\mathbf{y}=y_1,\cdots,y_n$ ，计算条件概率 $P(y_i|\mathbf{x})$ ， $P(y_i,y_{i+1}|\mathbf{x})$ 以及相应的数学期望。

预测问题： 给定条件随机场和观测序列 $\mathbf{x}=x_1,\cdots,x_n$ ，求使得条件概率 $P(\mathbf{y}|\mathbf{x})$ 最大的状态序列 $\mathbf{y}=y_1,\cdots,y_n$ ，即根据观测序列推断出隐藏的模式状态（词性标注、语音识别）。

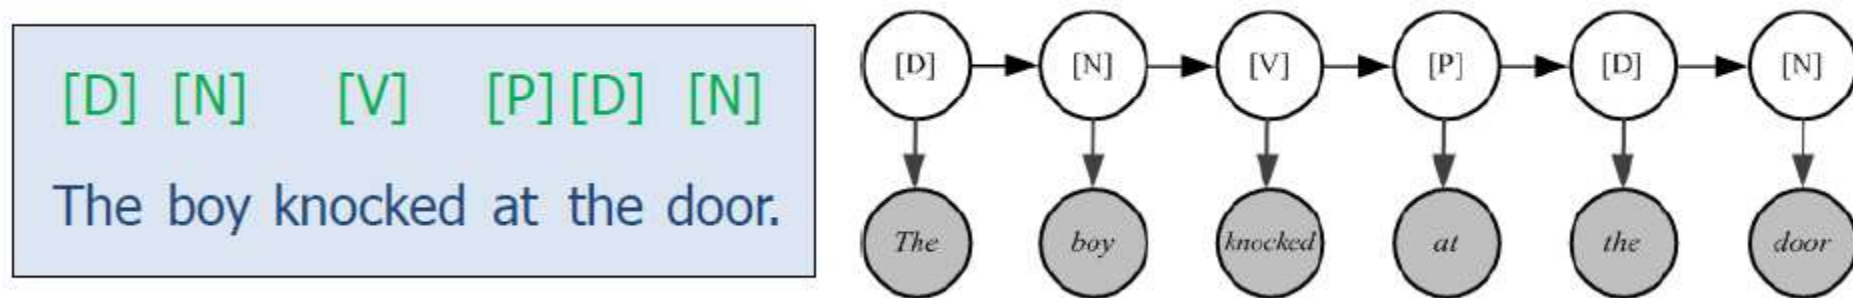
学习问题： 给定训练数据 $\{(\mathbf{x}_1,\mathbf{y}_1),(\mathbf{x}_2,\mathbf{y}_2),\cdots,(\mathbf{x}_S,\mathbf{y}_S)\}$ ，估计条件随机场的模型参数使得条件概率 $P(\mathbf{y}|\mathbf{x})$ 最大（训练模型使其能最好地描述训练数据）

自学《统计学习方法》李航，P207

条件随机场

示例：词性标注

利用隐马尔可夫模型进行词性标注：求解 $\text{argmax } P(\mathbf{y} | \mathbf{x})$





每个词的词性仅和自身有关，和文本中其他所有词均无关。建模联合概率 $P(\mathbf{x}, \mathbf{y})$ 。

事实上，观测到“at”对判断“knocked”的词性有帮助。

条件随机场

示例：词性标注

利用线性链条件随机场进行词性标注：



直接建模条件概率 $P(\mathbf{y}|\mathbf{x})$ ，通过定义适当的特征函数，当前词的词性可以和其他词相关。当下一个观测词是“at”时，当前词对应的词性标记很可能是[V]。

$$s_k(y_i, \mathbf{x}, i) = \begin{cases} 1, & \text{if } y_i = [V] \text{ and } x_{i+1} = \text{"at"} \\ 0, & \text{otherwise} \end{cases}$$

小结

1. 概率图模型

两类：贝叶斯网络（有向图）、马尔可夫随机场（无向图）。

掌握：概率分布分解形式、条件独立性。

2. 学习与推断

学习：结构学习、参数学习（最大似然估计、EM 算法）。

推断：精确推断（了解变量消去、信念传播）。

近似推断（了解前向采样、吉布斯采样）。

小结

3. 隐马尔可夫模型

三要素：A、B、 π 。

概率计算问题：掌握前向、后向算法。

预测问题：掌握维特比算法。

学习问题：了解最大似然估计和 EM 算法。

本讲参考文献

1. 《统计机器学习--第九章：概率图模型》课件，王泉，国科大网络安全学院，2017。

致谢王泉副研究员！感谢王泉提供了《概率图模型》课件供本章教学参考！